

Atividade Prática: Pipeline Modularizado de Classificação

Unidade Curricular de Engenharia de Dados & MLOps • Trabalho em Trio

FORMATO

Trio (3 Alunos)

FERRAMENTAS

VSCode & Python

1. Cenário de Negócio

Uma loja online deseja identificar clientes inativos com risco de não voltarem a comprar (Churn). O trio de estudantes deve construir uma **solução modularizada em Python** dividida em arquivos reutilizáveis no VSCode. A solução deve processar os dados brutos (`data/raw_transactions.csv`), aplicar uma **Tabela Dinâmica**, treinar um **modelo de classificação de livre escolha** (ex.: Árvore de Decisão, Regressão Logística, Random Forest) e realizar a inferência para um novo registro.

2. Divisão de Tarefas no Trio (Estrutura Modular)

Pessoa A: Engenharia de Dados

Criar o módulo `data_processing.py`. Ler `data/raw_transactions.csv`, aplicar `pd.pivot_table` para agregar valor por categoria e frequência, e gerar a coluna `churn` (1 para frequência < 8, senão 0).

Pessoa B: Ciência de Dados

Criar o módulo `model_training.py`. Receber os dados tratados, realizar a divisão treino/teste (70/30), treinar um **modelo de classificação de livre escolha** e retornar o modelo e métricas (Acurácia/Matriz de Confusão).

Pessoa C: MLOps & Integração

Criar o script principal `main.py`. Importar as funções dos módulos de A e B, coordenar a execução do pipeline e realizar a previsão final para um novo cliente de exemplo, exibindo o resultado no terminal.

3. Requisitos da Solução

- Modularização Obrigatória:** As responsabilidades de tratamento de dados e treinamento devem estar em arquivos Python separados (módulos) e importadas em `main.py`.
- Modelo de Livre Escolha:** A equipe pode escolher qualquer algoritmo de classificação do `scikit-learn` (ex.: `DecisionTreeClassifier`, `LogisticRegression`, `RandomForestClassifier`, etc.).
- Tabela Dinâmica:** Uso obrigatório de `pivot_table` para agregar a frequência de compras e os gastos por categoria por cliente.
- Execução Integrada:** O pipeline completo deve ser executado chamando apenas `python main.py` no terminal do VSCode.

4. Estrutura Esperada no VSCode

```
projeto_modular_trio/  
├── data/  
│   └── raw_transactions.csv # Dataset bruto de transações fornecido  
├── data_processing.py # Módulo de tratamento e pivot (Pessoa A)  
├── model_training.py # Módulo de treino e avaliação do modelo (Pessoa B)  
└── main.py # Script principal de orquestração e inferência (Pessoa C)
```

5. Rubrica de Avaliação

Critério	Peso	Descrição do Entregável
Engenharia de Dados (Pessoa A)	35%	Criação do módulo <code>data_processing.py</code> com leitura de CSV, <code>pivot_table</code> e geração da flag de churn.
Modelo de Classificação (Pessoa B)	35%	Criação do módulo <code>model_training.py</code> , escolha justificável/aplicação de algoritmo de classificação e cálculo de métricas.
Integração & Inferência (Pessoa C)	30%	Criação do <code>main.py</code> importando os módulos, executando o fluxo completo e realizando a previsão de um novo cliente sem erros.